

FraudAI
Détection de Fraude aux Remboursements de Santé
Business Case IA & Gouvernance
Cas d'usage : Assurance Maladie (CPAM)

Élément	Détail
Formation	MSc Machine Learning – EPITA 2026
Unité d'enseignement	ML Appliqué – Positionnement Business & Gouvernance IA
Type de fraude choisi	Fraude aux remboursements de santé (CPAM)
Dataset	Credit Card Fraud Detection – ULB / Kaggle (proxy anonymisé)
Modèle champion	XGBoost – AUC-PR 0,835 Recall 80,0 % (test) Precision 83,5 %
Responsable	Dr Alioune Nar SAMBE – INFORMATHS ENGINEERING FRANCE
Date de rendu	14 juin 2026
Auteur du document	DISSANG TENKAM FRANCIS KEVIN, JEHRRY JULES

Sommaire

1. Introduction et contexte

1.1 La fraude aux finances publiques en France

La fraude aux finances publiques constitue l'un des défis majeurs de l'administration française. En 2024, le gouvernement a détecté environ 20 milliards d'euros de fraudes, soit deux fois le budget de la Justice, et s'est fixé un objectif de 40 milliards d'euros détectés par an d'ici 2029 dans le cadre du Plan National de Lutte contre les Fraudes 2023-2027.

Indicateur clé	Chiffre 2024-2025
Fraudes détectées (toutes catégories)	~20 milliards € (2× budget Justice)
Fraudes sociales détectées (2025)	3,1 milliards € (+4,1 % vs 2024)
Fraudes Assurance Maladie (CNAM, 2025)	723 millions € (+15 %)
Objectif gouvernemental 2029	40 milliards € détectés / an

1.2 Une menace mondiale amplifiée par l'IA

À l'échelle mondiale, les pertes liées à la fraude dépassent 442 milliards de dollars en 2025. Les tentatives de fraude utilisant l'IA ont augmenté de 194 % en 2024 par rapport à 2023 (Group-IB). L'IA est désormais à la fois l'arme des fraudeurs et le principal rempart contre eux : c'est précisément ce paradoxe qui justifie l'investissement des organismes publics dans des systèmes de détection par Machine Learning.

2. Problème de fraude choisi : remboursements de santé (CPAM)

Parmi les types de fraude éligibles, nous retenons la fraude aux remboursements de santé gérés par l'Assurance Maladie (CPAM). Ce choix est justifié par trois facteurs : un enjeu financier documenté (723 M€ détectés en 2025, en hausse de 15 %), des données par nature sensibles qui maximisent les exigences de gouvernance et de RGPD, et un coût du faux positif particulièrement élevé sur le plan humain — suspecter à tort un assuré honnête.

2.1 Transposition du dataset au contexte CPAM

Le dataset bancaire ULB sert de proxy anonymisé d'un flux de remboursements de santé. La logique de détection est identique : un volume massif d'opérations légitimes, une minorité d'opérations frauduleuses, et des variables anonymisées par ACP qui reproduisent les contraintes du secret médical et de l'anonymisation RGPD.

Variable du dataset	Équivalent CPAM
Amount (montant transaction)	Montant du remboursement demandé
V1–V28 (composantes ACP)	Profil de remboursement anonymisé (secret médical)
Time / Hour	Horodatage de la demande
Class (0/1)	Fraude avérée après contrôle d'un agent

2.2 Business Problem Statement

Comment permettre aux agents de l'Assurance Maladie de prioriser leurs contrôles en ciblant automatiquement les demandes de remboursement à risque élevé, afin d'augmenter le taux de détection de fraude tout en réduisant le temps consacré aux contrôles non ciblés, sans jamais déléguer la décision finale à l'algorithme ?

3. Business Case IA

3.1 KPI cibles et résultats obtenus

Les objectifs ci-dessous correspondent aux cibles institutionnelles. Les résultats sont issus de l'exécution réelle (déterministe) du notebook, mesurés sur le jeu de TEST jamais touché (56 746 transactions, 95 fraudes) ;

les seuils et le choix du champion ont été calibrés sur un jeu de VALIDATION distinct (anti-fuite).

KPI	Cible	Résultat obtenu
Recall (taux de détection)	$\geq 80 \%$	80,0 % (test, seuil de déploiement)
Taux de faux positifs	$< 5 \%$	0,026 % (15 FP) ; 16,5 % des alertes (1-précision)
AUC-PR (métrique principale)	$> 0,80$	0,835
AUC-ROC	$> 0,95$	0,973
F1-Score (point équilibré)	$> 0,80$	0,821

3.2 Estimation budgétaire (projet pilote)

Poste budgétaire	Coût estimé
Équipe projet (data scientists, PM, juristes RGPD)	200 000 €
Collecte, préparation et qualité des données	80 000 €
Développement et optimisation du modèle ML	120 000 €
Interface agents (tableau de bord)	80 000 €
Infrastructure cloud / serveurs sécurisés	60 000 €
Sécurité, conformité RGPD et AI Act	60 000 €
Tests utilisateurs et formation des agents	50 000 €
Maintenance et monitoring (1ère année)	50 000 €
Total (projet pilote)	700 000 €

3.3 ROI et valeur créée

Hypothèses (illustratives, à confirmer avec les données réelles CPAM) : périmètre pilote d'une CPAM régionale concentrant environ 30 M€/an de fraude potentielle en scope. Sans FraudAI, le ciblage manuel en détecte une partie ;

avec FraudAI, la priorisation concentre les agents sur les dossiers à risque élevé. Les gains combinent la fraude supplémentaire détectée (taux de récupération conservateur) et le temps d'agent réaffecté.

Année	Valeur créée	Coûts	Flux net
Année 1 (montée en charge)	2,0 M€	0,70 M€	+1,30 M€
Année 2	3,3 M€	0,15 M€	+3,15 M€
Année 3	3,5 M€	0,15 M€	+3,35 M€
Total 3 ans	8,8 M€	1,00 M€	+7,8 M€

ROI sur 3 ans $\approx$ bénéfice net cumulé (7,8 M€) / coût total (1,0 M€) $\approx$ x7,8. Point mort atteint au cours de l'année 1. Ces chiffres sont volontairement conservateurs et présentés comme des hypothèses de cadrage, pas comme un engagement.

4. Dataset et analyse exploratoire

Caractéristique	Détail
Source	Kaggle – ULB Machine Learning Group
Volume brut	284 807 transactions (titulaires européens, 2013)
Après déduplication	283 726 transactions (1 081 doublons exacts retirés)
Variables	Time, V1–V28 (ACP), Amount, Class
Taux de fraude	0,167 % (473 fraudes)
Valeurs manquantes	Aucune
Montant médian fraude vs normal	9,82 € vs 22,00 €

4.1 Observations clés de l'EDA

- Déséquilibre extrême (1 fraude pour ~600 opérations) : impose un traitement spécifique et des métriques adaptées (AUC-PR, Recall) plutôt que l'accuracy.
- Les fraudes ont un montant médian plus faible (9,82 € contre 22,00 €) : signature des tests de petits montants par les fraudeurs.
- Les variables V14, V10, V12, V4 sont les plus discriminantes ; les V1–V28 étant anonymisées par ACP, leur interprétation passe obligatoirement par SHAP.
- 1 081 doublons exacts retirés : sans cette étape, les mêmes opérations présentes en train et en test gonfleraient artificiellement les performances (fuite de données).




Figure 1 — Déséquilibre des classes, distribution des montants et taux de fraude par heure.

5. Pipeline ML et modélisation

5.1 Architecture (prévention des fuites de données)

1. Split stratifié train / validation / test = 60 / 20 / 20 réalisé AVANT toute transformation.
2. Normalisation StandardScaler ajustée sur le train uniquement, puis appliquée au test.
3. Gestion du déséquilibre par optimisation du seuil de décision (champion XGBoost sans pondération ni SMOTE), seuil calibré sur la validation.
4. Benchmarking de 3 modèles, sélection du champion sur l'AUC-PR de validation ; métriques finales mesurées sur le test jamais touché.

5.2 Choix de la stratégie de déséquilibre

Erreur méthodologique classique : empiler un sur-échantillonnage SMOTE et une pondération `scale_pos_weight`, ce qui corrige deux fois un jeu déjà rééquilibré, écrase les probabilités du modèle et produit un seuil de décision pathologique ($\sim 1,0$).

Nous avons comparé proprement quatre stratégies sur XGBoost — sur la validation — et retenu celle qui maximise l'AUC-PR tout en conservant un seuil sain.

Stratégie de déséquilibre	AUC-PR (validation)	Seuil F1-opt (validation)
A. Optimisation de seuil (retenue)	0,8862	0,388 (sain)
B. <code>scale_pos_weight</code> seul	0,8857	0,998
C. SMOTE seul	0,8748	0,981
D. SMOTE + <code>scale_pos_weight</code> (à proscrire)	0,8524	0,9998 (pathologique)

5.3 Benchmark des trois modèles

Chaque modèle est évalué sur le test à son seuil F1-optimal calibré sur la validation. L'AUC-PR (validation) départage les modèles.

Modèle	AUC-ROC	AUC-PR	Recall	Precision	F1	FP	FN
Régression Logistique	0,964	0,689	0,737	0,886	0,805	9	25
Random Forest	0,950	0,786	0,726	0,885	0,798	9	26
XGBoost (champion)	0,973	0,835	0,726	0,945	0,821	4	26

Le XGBoost domine sur l'AUC-PR (0,835) et la précision (94,5 %), avec un seuil de décision sain de 0,39. C'est le modèle champion.




Figure 2 — Courbes ROC et Precision-Recall des trois modèles.

5.4 Seuil de décision : un curseur métier

Le seuil de décision n'est pas une constante technique mais un levier de politique de contrôle. Deux points de fonctionnement sont documentés :

- Point équilibré (F1-optimal, seuil 0,39) : Recall 72,6 %, Precision 94,5 %, 4 faux positifs. Maximise la précision — peu de dérangements d'assurés honnêtes.
- Point de déploiement (cible Recall ≥ 80 %, seuil 0,066) : Recall 80,0 % sur le test, Precision 83,5 %, 15 faux positifs (taux 0,026 %).
- Seuil calibré sur la validation avec une marge de généralisation ; atteindre 80 % de recall coûte en précision — compromis assumé et aligné sur le KPI institutionnel de détection.




Figure 3 — Matrices de confusion du champion : seuil naïf 0,50 vs seuil optimisé.

6. Explicabilité et IA responsable

Les variables V1–V28 étant anonymisées, le modèle serait une boîte noire sans explicabilité. Les valeurs SHAP permettent d'expliquer chaque score de risque, globalement et au niveau de chaque dossier, conformément à l'exigence de transparence de l'AI Act (droit à l'explication).




Figure 4 — Importance SHAP globale (impact moyen sur le score de risque).

Exemple d'explication locale produite par le notebook pour un dossier signalé (score 92/100) : les facteurs dominants sont V14, V10 et V12. L'agent reçoit ainsi, pour chaque alerte, les principaux facteurs explicatifs — base concrète d'une décision humaine éclairée et d'une réponse au citoyen en cas de recours.

6.1 Analyse des biais algorithmiques

Type de biais	Risque identifié	Mesure corrective
Socio-économique	Petits montants plus à risque → assurés précaires	Audit d'équité par décile de montant
Temporel	Concentration horaire des fraudes	Ajustement contextuel par type de prestation
Géographique / temporel	Données 2013, UE uniquement	Réévaluation sur données CPAM françaises récentes
Opacité ACP	V1–V28 non interprétables directement	SHAP obligatoire pour chaque alerte

7. Gouvernance IA, RGPD et AI Act

7.1 Classification réglementaire

FraudAI est un système d'IA à haut risque au sens de l'AI Act (Annexe III) : il est utilisé par une autorité publique pour évaluer des personnes physiques. Il est à ce titre soumis aux obligations les plus strictes d'auditabilité, de transparence et de supervision humaine.

Obligation réglementaire	Article	Application FraudAI
Décision non entièrement automatisée	RGPD Art. 22	Décision finale obligatoirement humaine
Système de gestion des risques	AI Act Art. 9	Roadmap de gouvernance sur 12 mois
Transparence et information	AI Act Art. 13	Documentation technique + SHAP disponibles
Supervision humaine	AI Act Art. 14	L'agent valide chaque alerte
Management de la qualité	AI Act Art. 17	Audit interne tous les 6 mois
Droit d'accès et de rectification	RGPD Art. 15-17	Procédure de recours citoyen définie

7.2 Data lineage

Source CPAM → Anonymisation / ACP → Chiffrement AES-256 → Pipeline scikit-learn → Score FraudAI (0–100) → Interface agent → Décision humaine → Feedback MLOps.

7.3 Roadmap de gouvernance (12 mois)

Mois	Jalon	Responsable	KPI de succès
M1-2	Audit des données, signature DPA, registre des traitements	DPO + Juridique	100 % données auditées
M3-4	Déploiement pilote (50 agents)	Lead Tech + MLOps	Recall ≥ 80 % en production
M5-6	Audit de biais initial + ajustements	Data Scientist	Disparate impact $< 1,25$
M7-8	Formation des agents + explicabilité	Équipe Formation	100 % agents formés
M9-10	Audit AI Act par tiers externe	Auditeur externe	Certification de conformité
M11-12	Bilan annuel, retraining, extension	Comité de pilotage	Drift < 5 % de dégradation

7.4 Monitoring et MLOps

- Monitoring hebdomadaire : distribution des scores, taux de FP/FN.
- Détection de drift : test de Kolmogorov-Smirnov sur les distributions des V1–V28 et du montant.
- Seuil d'alerte : dégradation du recall supérieure à 5 % sur une fenêtre glissante de 30 jours.
- Retraining : déclenché par un drift détecté ou tous les 3 mois avec de nouvelles données labellisées.
- Sécurité : chiffrement AES-256, accès restreint par rôle, authentification forte, journalisation de tous les accès et scores (auditabilité RGPD).

8. Déploiement — application web (React + FastAPI)

L'interface FraudAI est une application web (front React + Tailwind CSS, API FastAPI) destinée aux agents contrôleurs. Le backend charge le modèle sauvegardé (fraudai_model.pkl) et expose un endpoint de scoring ;

Le score affiché est donc strictement identique à celui du notebook. Pour chaque demande analysée, l'application restitue un score de risque 0–100 cohérent avec le modèle et son explication SHAP.




Figure 5 — Plateforme FraudAI (React + Tailwind + FastAPI), tableau de bord. Design noir/blanc/orange ; métriques (AUC-PR 0,835 ; Recall 80,0 % ; Précision 83,5 %) issues directement du modèle.




Figure 6 — Analyse d'un dossier : score 0–100, bande de risque, facteurs explicatifs SHAP (V14, V10, V12...) et rappel que la décision finale appartient à l'agent humain (RGPD Art. 22 / AI Act Art. 14).

- Saisie des paramètres de la demande et calcul du score de risque 0–100.
- Bandes de risque dérivées des seuils du modèle (t_{low} / t_{high}), garantissant la cohérence score / décision.
- Explication SHAP locale : principaux facteurs ayant influencé le score.
- Recommandation d'action et mention légale : la décision finale appartient à l'agent humain.

Score de risque	Niveau	Action recommandée
0 – 30	Risque faible	Traitement standard automatique

Score de risque	Niveau	Action recommandée
31 – 70	Risque modéré	File de contrôle selon ressources
71 – 100	Risque élevé	Contrôle prioritaire immédiat par un agent

9. Risques, limites et recommandations

Catégorie	Risque	Probabilité	Impact	Mesure
Technique	Concept drift (évolution des fraudes)	Élevée	Élevé	Retraining trimestriel
Technique	Attaques adverses (fraudeurs s'adaptant)	Modérée	Élevé	Monitoring des distributions
Éthique	Biais socio-économique (petits montants)	Modérée	Moyen	Audit d'équité semestriel
Éthique	Faux positifs pénalisant des assurés honnêtes	Faible	Moyen	Procédure de recours, seuil ajustable
Juridique	Non-conformité AI Act	Faible	Très élevé	Supervision humaine obligatoire
Données	Données 2013 non représentatives de 2026	Élevée	Élevé	Réentraînement sur données CPAM récentes

Limite principale assumée : le dataset (transactions bancaires 2013, UE) est un proxy. Le passage en production CPAM exige un réentraînement sur données de remboursement réelles et un nouvel audit de biais.

10. Conclusion stratégique

FraudAI démontre qu'un pipeline rigoureux (split train/validation/test, anti-fuite) atteint un bon compromis détection / précision sur le test jamais touché (AUC-PR 0,835 ;

Recall 80,0 % ; précision 83,5 %), avec un modèle explicable et conforme aux exigences RGPD et AI Act. La solution reste un outil d'aide à la décision : l'agent humain tranche.

Recommandation au comité décisionnel

Valider un déploiement pilote sur un périmètre CPAM régional, pour un budget de 700 000 € sur 8 mois, avec un objectif de détection accrue mesuré à 12 mois.

Trois conditions de réussite : réentraînement sur données CPAM réelles, audit de biais indépendant avant généralisation, et supervision humaine garantie sur chaque décision.
